

1 PORQUE ESTUDAR ESTATÍSTICA?

Pode ser que você ainda não saiba a importância da Estatística para a sua área, pode ser que você tenha imaginado que nunca mais iria se deparar com o raciocínio lógico ou a linguagem matemática. Durante este semestre, você terá a oportunidade de verificar como a produção de conhecimentos, muitas vezes, depende do pensamento e conceitos Estatísticos. Na verdade são conhecimentos essenciais para quem for seguir carreira acadêmica, pois além de permitir uma análise mais crítica das pesquisas nas áreas biológicas e da saúde, ajuda a ler o mundo, entender gráficos, tabelas e estatísticas que acompanham as notícias de jornais. Esta aprendizagem favorece a formação de um posicionamento crítico diante dos textos ou opiniões que muitas vezes manipulam os números ou não explicam devidamente a metodologia utilizada. Você também aprenderá como formular perguntas de interesse da ciência ou da sociedade que necessitem de uma análise de dados para serem respondidas.

1.1 COMO APRENDER ESTATÍSTICA?

Os docentes da área da Estatística da UNIRIO têm buscado transformar a relação dos estudantes com esta disciplina, incentivando a sua participação ativa durante o processo de aprendizagem. Considerando a importância do pensamento Estatístico na formação de qualquer profissional, cidadão ou pesquisador, as atividades práticas, o desenvolvimento de projetos e a elaboração de artigos tem permitido a motivação necessária à uma incorporação do conhecimento que não se limite à simples resolução de exercícios. Os conceitos serão aprendidos e exercitados em três módulos. Em cada um deles, o estudante percorrerá um processo que denominamos PAC referente ao Planejamento (P), Análise (A) e Conclusão (C).

1.2 CONVERSANDO NOS ENTENDEMOS

O estudante ao entrar na sala de aula traz consigo uma bagagem de experiências, sentimentos, expectativas, frustrações e muitas vezes, ansiedade. Uma pedagogia ativa deve considerar o aluno e sua aprendizagem no centro do seu planejamento e portanto precisa provocar sua vontade de se esforçar, de estudar, de aceitar desafios e aprender. Neste sentido, não espere um semestre fácil, muito pelo contrário, tanto nós professores, como vocês, estudantes, trabalhamos muito, porém, em mais sintonia e colaboração. Quanto mais vocês se dedicarem, mais ficarão surpresos e contentes com os resultados obtidos, que não serão os mesmos para todos. A metodologia utilizada respeita as diferenças, incentiva a solidariedade e colaboração entre vocês, mas também a criatividade e responsabilidade de todos.

1.3 QUAL A RESPONSABILIDADE DE CADA UM?

A do professor é o de orientar a aprendizagem descrevendo os objetivos de cada atividade a ser realizada e dando espaço e tempo na sala de aula e fora dela para sanar as dúvidas. Assim, você pode se organizar e ir avaliando sua aprendizagem. Muitas vezes a teoria só será apresentada e formalizada após a realização de alguma atividade que desperte a curiosidade e necessidade de conceitos ainda não vistos. No entanto, isto não significa que você não deva ler e procurar entender a teoria antes de fazer a atividade. Muito pelo contrário. Tenham certeza que se vocês assumirem o desafio de se comportarem como pesquisadores/profissionais com a vontade de aprender a aprender, muito terão a ganhar na sua vida pessoal e acadêmica.

1.4 E A AVALIAÇÃO DA APRENDIZAGEM?

Nesta metodologia é muito difícil e quase contraditório avaliar a partir apenas de uma prova com exercícios. É claro que a provas também avaliam e principalmente, preparam vocês para a realização de concursos. A proposta inicial (podendo ser melhor conversada) é que a nota neste módulo seja composta pela média ponderada de duas notas: i)um relatório de aprendizagem individual onde sejam descritos os conceitos aprendidos (com textos autorais). Este relatório substituirá a prova (para os que fizerem esta opção). Nele, deverão constar além das atividades realizadas, comentários que demonstrem a participação e os conhecimentos adquiridos a partir da interpretação crítica e reflexiva dos resultados; ii) a apresentação oral e escrita de um trabalho em grupo que permita exercitar também a colaboração, o respeito ao outro e as vantagens de uma criação coletiva;

1.5 QUAL O PROGRAMA A SER UTILIZADO?

O Programa R é o mais utilizado no mundo acadêmico por ser livre e constantemente atualizado a partir do desenvolvimento de novas bibliotecas. Para saber mais, faça uma busca no google e também leia a apostila do Professor Felipe Ribeiro [?]

1.6 OBJETIVOS DO MÓDULO 1

FRAME 1: HABILIDADES A SEREM DESENVOLVIDAS

Na finalização do primeiro módulo espera-se que todos :

- tenham escolhido um tema e trabalhado com um banco de dados oficial;
- saibam identificar as etapas de uma pesquisa quantitativa, incluindo a definição dos objetivos;[?]
- consigam elaborar/criticar um instrumento de coleta;[?][?]
- consigam identificar em cada estudo quantitativo quais as unidades de observação, quais as variáveis com suas devidas classificações e qual o desenho de estudo;[?]
- saibam transformar um banco de dados em um objeto R e criar um banco a partir de um instrumento de coleta[?]
- saibam fazer uma análise inicial utilizando gráficos e medidas descritivas

Atividades a serem realizadas no Módulo 1

- Atividade 1-Definição de um tema e elaboração de uma pergunta a ser respondida com dados
- Atividade 2-Conhecendo o R e o Rcmdr
- Atividade 3-Conceitos principais para um bom estudo quantitativo
- Atividade 4-Leitura e interpretação da metodologia e resultados de um artigo
- Atividade avaliativa- Elaboração de um relatório e uma apresentação em grupo
- Atividade avaliativa- Relatório de aprendizagem

1.7 CRONOGRAMA PRELIMINAR DAS AVALIAÇÕES

- Apresentação em grupo (4 pontos) dia 26 de abril
- Relatório de Aprendizagem (6 pontos) dia 5 de maio

2 OS CONCEITOS ESTATÍSTICOS NA COLETA DE DADOS

As dificuldades percebidas nos estudantes ou profissionais quando necessitam criar um instrumento de coleta ou mesmo uma planilha para inserir os dados já coletados, demonstram a necessidade de atividades que os façam perceber onde e de que forma o **pensamento estatístico** se faz necessário. Assim, neste primeiro módulo, através de atividades e dinâmicas de grupo, será demonstrado que desde o momento da definição dos objetivos do estudo é fundamental a identificação das **unidades de observação**. A ideia de que para existir Estatística é necessário que existam muitas unidades onde queremos ou temos observado ou realizado medidas em cada uma delas, que estas medidas variam entre elas e que os seus registros devem, por isso mesmo, serem os mais precisos possíveis, parece simples, mas muitas vezes, é uma das fontes das dificuldades percebidas durante toda aprendizagem. A falta de clareza a respeito deste conceito se traduz na elaboração do instrumento de coleta, na criação do banco de dados e em todas as etapas de análise.

2.1 O PLANEJAMENTO DE UMA PESQUISA

Inicialmente deve-se definir o objetivo do estudo. Para responder um objetivo que necessite um conjunto de informações a respeito de várias unidades (Ex. alunos, professores, bibliotecas escolares etc), é necessário definir algumas características destas unidades. Estas características são denominadas de variáveis do estudo. Algumas vezes as características a serem observadas são resultados de alguma medida realizada com algum instrumento (Ex. altura, peso, área etc). Outras vezes, são resultados de contagens (Ex. número de irmãos, número de livros etc). Algumas características são definidas apenas por categorias (Ex. sexo, tipo de livro, etc) Assim, os passos de uma pesquisa são os seguintes:

- Definir o objetivo;
- Escolher uma ou mais variáveis;
- Definir a unidade de observação (onde se mensura/observa a informação, Ex. alunos e biblioteca).

Exemplo 1: Identificar o perfil dos alunos da UNIRIO

Nosso objetivo é conhecer as características sócio-demográficas dos alunos da UNIRIO. As unidades de observação serão os alunos e para responder o nosso objetivo precisaremos das seguintes informações:

- Sexo: (F e M);
- Idade (anos completos);
- curso (;);
- Quanto tempo estuda aqui? (em meses);
- Nível de instrução do pai(sem instrução, Fundamental, Médio, superior;
- UF que nasceu;
- Município que reside; .

2.2 UNIDADES DE OBSERVAÇÃO E CLASSIFICAÇÃO DE VARIÁVEIS

A partir dos objetivos do estudo, devemos identificar quais serão as unidades de observação onde serão coletadas informações. Assim, para fazer um diagnóstico, por exemplo, dos fatores que influenciam o posicionamento político dos estudantes da UNIRIO, estamos partindo da hipótese de que existe variabilidade entre eles em relação a esta e outras características. Neste caso, de forma simples, identifica-se que os estudantes são as unidades de observação. Os conceitos que permitirão indicar os procedimentos para a seleção dos mesmos serão vistos no módulo 2, mas é intuitivo que esta escolha não poderá ser feita sem levar em conta critérios que não distorçam o resultado, como por exemplo, escolher estudantes apenas na entrada ou saída de um auditório onde aconteceu ou acontecerá um debate. E se o objetivo fosse o de identificar os fatores que poderiam intervir na riqueza e outras características de uma determinada família de plantas? ou ainda, que fatores poderiam influenciar a maior ou menor ocorrência de casos de microcefalia nos municípios brasileiros? Percebe-se que, ás vezes, a identificação das unidades de observação ou unidades experimentais não é muito simples, ou outras vezes não são unidades individuais. Aqui, vamos refletir primeiro a respeito do que devemos coletar em cada uma das pesquisas para obter os diagnósticos que pretendemos. A escolha do que e como vamos medir em cada unidade, nos levará a necessidade de entendermos que estas medidas são denominadas de variáveis e que será importante conhecer como elas se classificam.

2.3 CLASSIFICAÇÃO DE VARIÁVEIS

Uma variável pode ser qualitativa ou quantitativa.

Variável qualitativa: quando os possíveis resultados são atributos ("qualidades").

Variável quantitativa: quando os possíveis resultados são *numéricos* (em geral, resultado de contagem ou medida).

- Exemplos de variáveis qualitativas: Sexo; Nível de instrução; Tipo de medalha recebida.
- Exemplos de variáveis quantitativas: Número de livros; Idade; Tempo de formado.

Uma variável qualitativa pode ser *nominal* ou *ordinal*:

FRAME 2: VARIÁVEIS QUALITATIVAS

- Qualitativa nominal: quando os possíveis resultados não apresentam uma ordenação natural. Por exemplo, *sexo* é uma variável qualitativa nominal.
- Qualitativa ordinal: quando os possíveis resultados apresentam uma ordenação natural. Por exemplo, Tipo de medalha (bronze, prata e ouro) é uma variável qualitativa ordinal.

Uma variável quantitativa pode ser discreta ou contínua:

FRAME 3: VARIÁVEIS QUANTITATIVAS

- **Quantitativa discreta**: Em geral, resultado de alguma contagem. Por exemplo, número de livros em uma residência é uma variável quantitativa discreta.
- **Quantitativa contínua**: Em geral, resultado de alguma medição. Por exemplo, o *tempo de formado e idade* são exemplos de variáveis quantitativas contínuas.

2.4 ELABORAÇÃO DE UM INSTRUMENTO DE COLETA DE DADOS

Após a definição dos objetivos gerais e específicos e da determinação dos procedimentos para seleção das **unidades de observação** (a ser visto no módulo 2), é necessário definir quais as variáveis a serem coletadas e de que forma serão registradas as informações. No caso de um questionário estruturado (com perguntas fechadas e de múltiplas escolhas), ou em um formulário de coleta, deve-se levar em conta :

- as categorias das variáveis qualitativas ordinais devem ser apresentadas na ordem;
- ao coletar variáveis quantitativas contínuas ou discretas em intervalos, perde-se precisão;
- as perguntas, ou as definições das medidas que se deseja, devem ser claras e concisas;
- ⇒ A Estatística está presente nas diversas etapas de uma pesquisa, desde o seu planejamento até a interpretação dos seus resultados.

⇒ Qualquer pesquisa que envolve coleta de dados de diferentes unidades/indivíduos necessita o uso de técnicas estatísticas para *analisar tais dados* e, responder às questões que deram origem à pesquisa.

FRAME 4: CLASSIFICAÇÃO DE QUATRO DAS VARIÁVEIS DO EXEMPLO 1:

- sexo: variável qualitativa nominal
- nível de instrução: variável qualitativa ordinal
- idade: variável quantitativa contínua
- tempo de estudo: variável quantitativa contínua

\rightarrow Por que é importante saber classificar variáveis na hora de elaborar um questionário?

• Na hora de elaborar um questionário é importante saber sua classificação para coletar a informação corretamente. É errado, por exemplo, apresentar as categorias de uma variável qualitativa ordinal fora da ordem.

FRAME 5: SEGUNDO EXEMPLO DE QUESTIONÁRIO.	
Sexo: () Masculino Feminino	
2. Você já teve aula de algum conteúdo estatístico? () Sim () Não	
 3. Qual o nível de instrução do seu pai? () Sem Instrução () Ensino fundamental () Ensino médio () Ensino Superior 	
4. Quantas pessoas moram na sua casa (contando com você)?	
5. Qual a renda familiar mensal (em salários mínimos)?	

\rightarrow Por que é importante saber classificar variáveis na hora de escolher o gráfico ou as medidas?

- Na hora de escolher um gráfico é fundamental saber se é apropriado para o tipo de variável. Um gráfico de Pizza só é apropriado para representar variáveis qualitativas nominais (com poucas atributos), mas o gráfico de Barras pode representar bem, tanto as variáveis qualitativas nominais, quanto as ordinais. Na representação de uma variável quantitativa contínua, o histograma ou Boxplot são os mais apropriados.
- Analogamente, devemos utilizar medidas resumo apropriadas para descrever o comportamento das variáveis observadas. Para as variáveis qualitativas devemos utilizar a proporção. (exemplo: proporção de mulheres na turma, proporção de professores que lecionam no ensino superior, etc).
- Para as variáveis quantitativas, a média e a mediana são medidas que resumem as informações em um único valor. No entanto, a média é influenciada por valores discrepantes e é bastante afetada se apenas um valor for muito modificado. Neste caso, o valor mediano que significa que 50% das observações estão abaixo dele, não se alteraria.

• Para expressar a variabilidade de variáveis quantitativas, pode-se utilizar o Intervalo interquartílico (diferença entre os quartis), a amplitude (diferença entre o maior e o menor valor) ou o desvio-padrão (expressa o quanto os valores variam em torno da média).

3 ORGANIZAÇÃO DOS DADOS

Uma vez coletadas as informações de interesse da nossa pesquisa, o próximo passo é *organizar tais informações em uma planilha*, formando assim o que chamamos de um *banco de dados*. Dois conceitos são fundamentais para compreensão de um banco de dados:

3.1 CRIAÇÃO DE UM BANCO DE DADOS

A falta de entendimento de como os programas estatísticos lerão e farão a análise dos dados, deve ser a razão de muitos equívocos na criação do Banco de dados. As atividades de criação de um banco de dados a serem realizadas neste módulo, pretendem fixar o entendimento de que cada linha da base tem que ser uma Unidade de observação e cada coluna é referente à cada uma das variáveis.

Unidade de observação: Cada linha do banco de dados representa uma unidade de observação. No Exemplo 1, cada aluno inscrito no curso é uma unidade. Em uma pesquisa com bibliotecas escolares, cada biblioteca representaria uma unidade.

Variável: Características de interesse (representadas em cada coluna do banco de dados) que variam entre as unidades.

FRAME 6: COMO ORGANIZAR AS INFORMAÇÕES EM UMA PLANILHA DE MANEIRA PRÁTICA? A A

- Associar, a cada *observação*, uma *linha* da planilha;
- Associar, a cada variável, uma coluna da planilha (opcionalmente, fazer da primeira coluna uma coluna de identificação das observações);
- Em particular, a *primeira linha* da planilha é utilizada para identificar as variáveis, sendo a primeira coluna a identificação das Unidades.

4 ESTUDO DIRIGIDO- ANÁLISE E INTERPRETAÇÃO DOS DA-DOS

Para responder as questões de um estudo, é fundamental que saibamos as ferramentas que a Estatística nos oferece, mas o mais importante mesmo é sabermos utilizá-las corretamente e interpretar os resultados obtidos. Não existe um caminho único para responder as questões, analisar um Banco de dados e também escrever um texto que interprete os resultados. No entanto, existem interpretações erradas ou escolha equivocada da medida ou gráfico que ajudará na resposta. Até este momento do curso vimos as medidas de posição (média, moda, mediana e quartis) e de variabilidade (desvio-médio, desvio-padrão, variância, coeficiente de variação, amplitude e intervalo interquartílico).

4.1 UTILIZEO BANCO DE DADOS ANALFABETOSANO.CSV E RESPONDA AS SEGUINTES QUESTÕES

I) Descreva a distribuição das variáveis (porcentagem de famílias pobres) considerando todas as observações (Ufs X Ano). Repita, analisando estas distribuições por região.

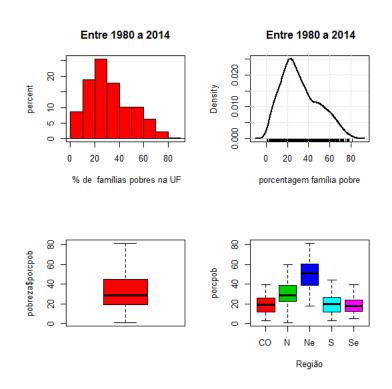


FIGURE 1

- O histograma, o Boxplot e as medidas descritivas permitem verificar que a porcentagem de famílias pobres variaram no período desde 0.5% até 81% de famílias com uma ligeira assimetria à direita com 32% em média e mediana de 28%.
- A variabilidade pode ser medida também pelo desvio-padrão de 17 e Intervalo interquartílico de 26. No Boxplot da porcentagem de famílias pobres por região, verifica-se que

- a Região nordeste destaca-se, tanto por apresentar os maiores valores, quanto a maior dispersão também.
- II) Verifique a partir de medidas e gráficos, a distribuição e variabilidade da porcentagem de famílias pobres nas Ufs das Regiões Nordeste e Sudeste separadamente Interprete os resultados.

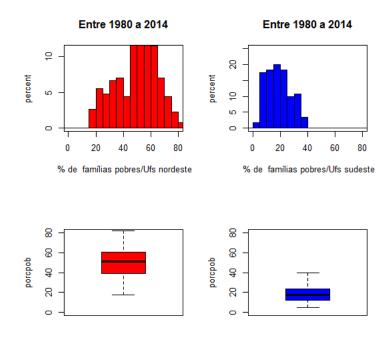


FIGURE 2

- Os dois histogramas demonstram a diferença das distribuições da porcentagem de famílias pobres nas duas regiões no período. As duas são razoavelmente simétricas, mas posicionadas em valores diferentes.
- Enquanto na região nordeste a distribuição inicia em 18% e possui uma grande concentração entr 40% e 60%, na região sudeste, a distribuição da porcentagem de famílias pobres inicia em torno de 5%, tem uma grande concentração em torno de 20% e seu maior valor em torno de 40%.
- Os Boxplots complementam esta análise e confirmam as diferenças entre as duas distribuições, que se distinguem tanto em relação às medidas de posição (média e quartis), quanto em relação às medidas de variabilidade (Intervalo interquartílico e desviopadrão).
- A comparação entre o IQR e o desvio-padrão desta variável nas regiões, indicam que no nordeste eles são de 21% e 15%, enquanto que no sudeste são bem inferiores, com valores de 12% e 9

5 INTRODUÇÃO-SEGUNDO MÓDULO

Conhecer o Pensamento Estatístico é importante tanto para quem vai fazer uma pesquisa quantitativa no seu TCC, mestrado ou doutorado, mas também para todos os cidadãos que precisam entender as notícias, os resultados de pesquisas e suas interpretações. No primeiro módulo reforçamos as etapas do planejamento de um estudo quantitativo, iniciando com a definição dos objetivos, discutindo a construção do instrumento de coleta e como definir as unidades de observação ou unidades amostrais. Agora, vamos refletir sobre a forma que estas unidades devem ser selecionadas para que representem a população estudada. Será a hora também de exercitar mais a leitura e interpretação de gráficos, tabelas e medidas estatísticas, para utilizar de forma consciente, tanto na vida cidadã, quanto na vida acadêmica e profissional. Neste módulo serão vistos conceitos estatísticos fundamentais. Vocês irão conhecer a respeito de amostragem e erros amostrais, distribuições de probabilidades, intervalo de confiança, Teste de Hipóteses e análise de correlação.

5.1 QUAIS OS CONCEITOS NOVOS DO MÓDULO?

Neste módulo, vocês continuarão a fazer análises no R, mas não se esqueçam que o objetivo principal da disciplina é que você entenda os resultados vindos de uma amostra da população e saiba avaliá-los. Para isso, você precisa entender bem como os conceitos de variabilidade e incerteza são fundamentais. De onde vem a incerteza em um estudo quantitativo? como medíla, como descrevê-la e como nomeá-la? As incertezas serão medidas com probabilidades e você precisará delas para entender e decidir sobre hipóteses e estimativas realizadas.

5.2 COMO DEFINIR SUA POPULAÇÃO ALVO E COMO SELECIONAR AS UNIDADES DE OBSERVAÇÃO?

A formulação do objetivo do estudo com escolha das unidades de observação e variável principal, é uma etapa fundamental e anterior à qualquer processo de coleta de dados. A partir dela é necessário definir qual a população alvo do estudo e como será o processo de escolha das unidades. Este processo de escolha deve buscar garantir uma boa estimativa tanto da variabilidade, quanto de alguma medida descritiva que responda ao objetivo. A partir de alguns exemplos de objetivos, vamos refletir sobre os possíveis processos de seleção das unidades:

- O objetivo é estimar a porcentagem de domicílios no Rio de Janeiro chefiados por mulheres;
- O Objetivo é o de comparar a ocorrência de uma determinada espécie entre três praias cariocas;

6 INFERÊNCIA E AMOSTRAGEM

Para atingir os objetivos acima, são necessários os conceitos de amostragem e de inferência estatística. Os de amostragem para definir os procedimentos de seleção das unidades que farão parte da amostra e os de inferência para calcular os erros amostrais envolvidos nas estimativas obtidas e a partir deles, decidir a respeitos das hipóteses.

6.1 AMOSTRA ALEATÓRIA SIMPLES

Cada elemeto da amostra tem a mesma probabilidade de ser selecionada. Apesar de ser o mais garantido caminho de seleção, é também o mais difícil e raro de ser executado. No caso do primeiro objetivo, mesmo que existisse um cadastro de todos os domicílios do Rio de Janeiro, uma amostra de domicílios obtida a partir de uma seleção com igual probabilidade estaria tão espalhada no Rio que seria impossível (cara e demorada) fazer esta pesquisa.

6.2 AMOSTRA AELATÓRIA ESTRATIFICADA

Para espalhar menos a amostra a população de domicílios poderia ser dividida em sub-populações (poderiam ser as regiões do Rio de Janeiro) e em cada sub-população (denominada estrato), seria realizada uma amostra aleatória de domicílios. Este tipo de amostragem visa garantir que a amostra final tenha a mesma variabilidade da poulação, com um menor custo. A exigência portanto é que cada estrato seja homogêneo e o conjunto dos estratos represente a heterogeneidade total. Os principais motivos para este tipo de amostragem:

- decrescer a variabilidade das estimativas (erro amostral)
- poder empregar métodos diferentes em cada estrato
- poder constituir estratos de natureza diferente

6.3 AMOSTRA POR CONGLOMERADOS

Neste tipo de amostragem, as unidades amostrais que serão selecionadas em um primeiro estagio, contém muitos elementos da poulação denominados conglomerados que devem ser bastante heterogêneos e representando a heterogeneidade da população. No exemplo da amostra dos domicílios, antes de dividÍ-los em estratos por região, poderíamos primeiro selecionar bairros (conglomerados)

6.4 AMOSTRAGEM SISTEMÁTICA

Neste tipo de amostragem considera-se os elementos da população em alguma ordem (alfabética, numérica ou temporal

7 HABILIDADES A SEREM DESENVOLVIDAS NO MÓDULO

Na finalização do módulo os alunos deverão saber:

- identificar as características das principais técnicas de amostragem;
- entender como os conceitos de variabilidade e incerteza influenciam em uma análise de dados vindos de uma amostra;
- definir objetivos que necessitem análises com mais de uma variável e escolher e interpretar os gráficos e medidas que permitam avaliar estes objetivos;
- conhecer as principais distribuições discretas e contínuas de probabilidade;
- conhecer os pincipais conceitos para calcular margens de erros, intervalos de confiança e realizar testes de hipóteses;

7.1 ATIVIDADES PRELIMINARES PARA FINALIZAR O MÓDULO 2

- Atividade 1 Exercitando os conceitos e tipos de amostragem e entendendo o significado de erro amostral.
- Atividade 2- Como planejar um desenho amostral na área da Biologia;
- Atividade 3- Utilizando os conceitos em um experimento;

7.2 AVALIAÇÃO DO SEGUNDO E TERCEIRO MÓDULOS

- Relatório de aprendizagem (peso 7- dia 9 de junho)
- Apresentação do tema do trabalho, com objetivos, variáveis e métodos de análise (peso 3- dia 22 de junho).
- Artigo escrito (peso 7-julho)
- Apresentação do artigo (peso 3- 30 de junho)